Mise en œuvre d'un « DATA LAKEHOUSE »

A partir de données HTML issues des sites LinkedIn et Glassdoor

1. Objectif pédagogique global du projet

Finalité du TD

- Mettre en œuvre un pipeline complet de traitement et d'ingestion de données.Depuis la collecte des données brutes de type HTML, jusqu'à la visualisation avec un outils de BI, en passant par leurs traitements pour chacune des zones du Data Lakehouse.
- Etude et réalisation du processus complet de création de ce Data Lakehouse.
- Ce travail sert à comprendre et appliquer les principales étapes techniques et méthodologiques de la chaîne de traitement des données dans sa conception et sa réalisation, c'est-à-dire :

Collecte → Ingestion → Extraction → Transformation → Analyse / Reporting.

Les sources sont des **fichiers HTML** issus du web : Offres d'emploi (INFO-EMP), Informations sur les entreprises (INFO-SOC) et Avis donnés par des employés sur ces entreprises (AVIS-SOC).

Ces fichiers HTML proviennent des sites professionnels d'emplois **GLASSDOOR** et **LINKEDIN** .

Types de livrables attendus :

- Scripts Python (Phases 1, 2 + éventuellement 3 et 4).
- Fichiers CSV de métadonnées (techniques et descriptives).
- Traitement de type ETL pour l'alimentation des données dans la partie BI finale (Phase 3)
- Modèle décisionnel à concevoir et à réaliser (étoile, flocon, …)
- Tableaux de bord BI (Maquettes, puis produit final) (Phase 4).
- Etc…

2. Les phases principales du projet

Phase 0 — Recherche des sources de données

- Aucun travail à réaliser
- Considérer le dossier « **0_SOURCE_WEB** » comme la source de vos données.
- Les données sources sont des fichiers HTML et sont fournies dans ce dossier.

Phase 1 — Ingestion (en LANDING ZONE)

- Copier les fichiers HTML depuis « **0_SOURCE_WEB** » vers « **1_LANDING_ZONE** ».
- Enregistrer « simultanément » dans un fichier CSV les « **métadonnées techniques** »: (ex. : date de récupération, chemin du fichier source, chemin du fichier cible, type d'objet, catégorie, etc.)
- [Automatiser l'ingestion et journaliser les opérations]

📂 Exemple d'arborescence :

```
C:\TD_DATALAKE\DATALAKE\
   ├── 0_SOURCE_WEB
   │
   ├── 1_LANDING_ZONE
   │    ├── LINKEDIN\EMP
   │    ├── GLASSDOOR\SOC
   │    ├── GLASSDOOR\AVI
   │    └── METADONNEES
   │
   ├── 2_CURATED_ZONE
   │    └── METADONNEES
   │
   ├── 3_PRODUCTION_ZONE
   │    ├──
```

Livrables :

- Scripts Python
- Les fichiers sources copiés en LANDING ZONE
- Le fichier des « métadonnées techniques »
- [les fichiers logs des erreurs de traitement].

Phase 2 — Extraction (en CURRATED-ZONE)

- Lecture du fichier de **« métadonnées techniques »** pour localiser et traiter chaque fichier HTML présents en **LANDING ZONE**.
- Extraction et stockage dans un fichier CSV des **« données descriptives »** contenues dans les fichiers HTML : (ex. : nom de société, ville de la société, intitulé emploi, avis sur la société, note moyenne, etc.)
- Ajouter en plus de celles fournies, de nouvelles fonctions d'extraction en Python pour enrichir les données descriptives extraites.

Livrables :

- Script Python.
- Fichier de « métadonnées descriptives »

Phase 3 — Traitement ETL et Entrepôt de données (DataWareHouse)

- A partir du fichier des **« métadonnées descriptives »** et d'un **ETL** (ou d'un développement python équivalent) : Transformation, enrichissement et chargement des données vers la zone BI analytique dans **« 3_PRODUCTION_ZONE »** (= REFINED ZONE) dans le cas de fichiers CSV.
- Modélisation et implémentation d'une structure de données décisionnelle (étoile, flocon) qui constituera votre **Data Warehouse** pour la **BI** en « **Phase 4** ».

Livrables :

- Scripts ETL.
- Modèle de données décisionnel implémenté.

Phase 4 — Mise en place du Reporting / Analyse

- Conception de **Tableaux de bord BI**.
- Outils d'analyse exploratoire et d'affichage des données extraites.
- Évaluation de la qualité du Data Lakehouse.

Livrables :

- Rapports d'analyses dynamiques, statistiques et opérationnels sous forme de Tableau de bord BI

3. Architecture technique

Zones du Data Lake

Zone	Rôle	Contenu
0_SOURCE_WEB	Données sources brutes (HTML)	Fichiers HTML source Linkedin etGlassdoor
1_LANDING_ZONE	Zone d'ingestion données brutes	Fichiers HTML copiés + Fichier CSV Métadonnées Techniques
2_CURATED_ZONE	Zone extraction données descriptives (extraction et nettoyage)	Fichier CSV Métadonnées descriptives
3_PRODUCTION_ZONE	Zone analytique	Données structurées en modèle décisionnel pour la BI (Si stockage en fichiers)

4. Bonnes pratiques

- Collecte **non destructive** de objets sources (!!! Modification des objets sources interdite).
- Traçabilité via les **Métadonnées techniques**.
- Utiliser une structure des données « **vertical** » pour les fichiers métadonnées (évolutivité facilité).