PHASE 1 / PHASE 2

Etude de la structure des « Méta-données » dans un « Data Lakehouse »

Modèle type de structure d'implémentation logique et physique des Méta-Données dans un Datalake :

➔ Deux Types de Méta-données à traiter :

- **TECHNIQUE** : (Exemple : D'où vient le fichier, Date de récupération, Taille du fichier, ...)
- **DESCRIPTIVE** : (Exemple : Nom de l'entreprise, La ville, ...)

➔ Utilisez les exemples d'implémentation ci-dessous pour réaliser les parties « **PHASE 1** » et « **PHASE 2** » du TD.

Lorsque vous réaliserez ces traitements en Python, vous pourrez vous inspirer du code donné en exemple en « **ANNEXE 1 »** de ce document.

Pour les « PHASE 1 » et « PHASE 2 », vous utiliserez deux fichiers distincts pour enregistrer respectivement les métadonnées techniques et les métadonnées descriptives. Ces deux fichiers auront la même structure de données.

Vous les stockerez dans un emplacement réfléchi et bien nommé sur disque.

Question : Réfléchissez aux avantages et inconvénients de cette structure (Verticale) où la création d'une nouvelle colonne se fait en rajoutant une ligne, en regard d'une structure classique (Horizontale) où chaque type de données extraite nécessiterait la création d'une nouvelle colonne.

Exemple de fichier de « Meta-Données Techniques »:

« OBJET_ID » => Représente dans, l'**identifiant unique de l'objet Source** stocké en **LANDING_ZONE** dans votre DataLake (le fichier HTML dans notre cas). Appelé « *ROW ID » dans votre cours* .

« OBJET_ID + COLONNE » => Représente l'**identifiant composite unique de la donnée extraite cet objet.**

```
"OBJET_ID";"COLONNE";"VALEUR"
"16308" ; "date_heure_de_recuperation" ; "2025-02-13 12:32:45"
"16308" ; "nom_du_fichier_source" ; "13546-INFO-EMP-LINKEDIN-FR-1599984246.html"
"16308" ; "provenance_du_fichier_source" ; "C:\TD_DATALAKE\DATALAKE\0_SOURCE_WEB\"
"16308" ; "nom_du_fichier_cible" ; "13546-INFO-EMP-LINKEDIN-FR-1599984246.html"
"16308" ; "localisation_du_fichier_cible" ; "C:\TD_DATALAKE\DATALAKE\1_LANDING_ZONE\LINKEDIN\EMP\"
"16308" ; "type_du_fichier_source" ; "html"
"16308" ; "categorie_du_fichier_source" ; "INFO_EMPLOI"
......
"4216" ; "date_heure_de_recuperation" ; "2022-11-25"
"4216" ; "nom_du_fichier_source" ; "13552-INFO-SOC-GLASSDOOR-E2131167_P1.html "
"4216" ; "provenance_du_fichier_source" ; "C:\TD_DATALAKE\DATALAKE\0_SOURCE_WEB\"
"4216" ; "nom_du_fichier_cible" ; "13552-INFO-SOC-GLASSDOOR-E2131167_P1.html"
"4216" ; "localisation_du_fichier_cible" ; "C:\TD_DATALAKE\DATALAKE\1_LANDING_ZONE\GLASSDOOR\SOC\"
"4216" ; "type_du_fichier_source" ; "html"
"4216" ; "categorie_du_fichier_source" ; "INFO_SOCIETE"
......
```

Exemple de fichier de « Meta-Données Descriptives »:

```
"OBJET_ID";"COLONNE";"VALEUR"
"16308" ; "nom_entreprise" ; "Business & décision"
"16308" ; "ville_entreprise","Lyon 7 eme"
"16308" ; "note_entreprise","3,2"
......
"4216" ; "nom_entreprise" ; "Sopra Group "
"4216" ; "ville_entreprise","Paris 15 ème"
"4216" ; "note_entreprise","2,5"
......
......
```

ANNEXE 1

```
# -*- coding: utf-8 -*-

#=============================================================================================
#  Auteur: Eric KLOECKLE
#  Etablissement: Université Lumière Lyon 2 - Bron
#  Cursus: Master 2  BI&A : « Business Intelligence & Analytics »
#  Domaine: « Gestion de données massives »
#  Cours: Enseignement TD Datalake-House
#
#---------------------------------------------------------------------------------------------
# 00-PHASE-1_Etude_de_la_Structure_type_des_Metadonnees_dans_un_Datalake_v0.01.py
#=============================================================================================


#############################################################################################
#############################################################################################
#
# Outils
#
#############################################################################################
#############################################################################################

#=============================================================================
#-- Afficher_une_ligne
#=============================================================================
def Afficher_une_ligne(caractere = "-", nombre_de_caractere=80):
    print(caractere*nombre_de_caractere)


#=============================================================================
#-- Sauter_une_ligne
#=============================================================================
def Sauter_une_ligne():
    print()


#=============================================================================
#-- Suppression du chaine_de_caractere "\n" (retour chariot) dans une chaine de chaine_de_caractere
#   => Utilisation des "regular expression" - bibliotheque Python "re"
#=============================================================================
import re
def Supprimer_SautDeLigne(chaine_de_chaine_de_caractere):
    resultat = ""
    print(re.sub(r'(.*)\\n','' r'\1', str(chaine_de_chaine_de_caractere)))
    return(resultat)
```

```
#################################################################################################
#################################################################################################
#
# Exemple: passage de "Liste" vers "Fichier CSV" et inversement
#
#################################################################################################
#################################################################################################


#=============================================================================
#=============================================================================
#  Passage d'une liste vers un CSV
#=============================================================================
#=============================================================================


#-- Chargement de la bibliotheque python pour la manipulation des fichiers CSV
import csv


#=============================================================================
# Création d'un jeux de test (factice)
# pour générer un exemple de fichier de metadonnées technique
#=============================================================================
liste_lignes_metadonnee_technique_OUT =  [
                    ['OBJET_ID'    , 'COLONNE', 'VALEUR'],
                    ['16308' , 'date_heure_de_recuperation' , '2025-02-13 12:32:45'],
                    ['16308' , 'nom_du_fichier_source' , '13546-INFO-EMP-LINKEDIN-FR-1599984246.html'],
                    ['16308' , 'provenance_du_fichier_source' , 'C:\\TD_DATALAKE\\DATALAKE\\0_SOURCE_WEB\\' ],
                    ['16308' , 'nom_du_fichier_cible' , '13546-INFO-EMP-LINKEDIN-FR-1599984246.html'],
                    ['16308' , 'localisation_du_fichier_cible' , 'C:\\TD_DATALAKE\\DATALAKE\\1_LANDING_ZONE\\LINKEDIN\\EMP\\'],
                    ['16308' , 'type_du_fichier_source' , 'html'],
                    ['16308' , 'categorie_du_fichier_source' , 'INFO_EMPLOI'],
                    ['4216' , 'date_heure_de_recuperation' , '2022-11-25'],
                    ['4216' , 'nom_du_fichier_source' , '13552-INFO-SOC-GLASSDOOR-E2131167_P1.html '],
                    ['4216' , 'provenance_du_fichier_source' , 'C:\\TD_DATALAKE\\DATALAKE\\0_SOURCE_WEB\\'  ],
                    ['4216' , 'nom_du_fichier_cible' , '13552-INFO-SOC-GLASSDOOR-E2131167_P1.html'],
                    ['4216' , 'localisation_du_fichier_cible' , 'C:\\TD_DATALAKE\\DATALAKE\\1_LANDING_ZONE\\GLASSDOOR\\SOC\\'],
                    ['4216' , 'type_du_fichier_source' , 'html'],
                    ['4216' , 'categorie_du_fichier_source' , 'INFO_SOCIETE']]



#=============================================================================
# Création d'un jeux de test (factice)
# pour générer un exemple de fichier de metadonnées descriptive
#=============================================================================
liste_lignes_metadonnee_descriptive_OUT =  [['OBJET_ID'    , 'COLONNE', 'VALEUR'],
                    ['16308' , 'nom_entreprise' , 'Business & décision'],
                    ['16308' , 'ville_entreprise','Lyon 7 eme'],
                    ['16308' , 'note_entreprise','3,2'],
                    ['4216' , 'nom_entreprise' , 'Sopra Group'],
                    ['4216' , 'ville_entreprise','Paris 15 ème'],
                    ['4216' , 'note_entreprise','2,5']]
```

```
#-------------------------------------------------------------------------------
#-- Visualisation du contenu de la liste de ligne à enregistrer dans un fichier
#-------------------------------------------------------------------------------
Sauter_une_ligne()
Afficher_une_ligne('-', 80)
for myLineOut in liste_lignes_metadonnee_technique_OUT : print(myLineOut)
Afficher_une_ligne()


#===============================================================================
# Préparation et création des fichiers de métadonnées
#===============================================================================
repertoire_fichier_metadonnee_OUT = "C:/TD_DATALAKE/DATALAKE/2_CURATED_ZONE/METADONNEES"
nom_du_fichier_metadonnee_technique_OUT = "metadonnee_technique.csv"
nom_du_fichier_metadonnee_descriptive_OUT = "metadonnee_descriptive.csv"



#-------------------------------------------------------------------------------
# Traitement de création du fichier de métadonnées technique
#-------------------------------------------------------------------------------
#-- Ouverture du fichier CSV métadonnées techniques en écriture
objet_fichier_csv_OUT = open(repertoire_fichier_metadonnee_OUT + '/' + nom_du_fichier_metadonnee_technique_OUT, "w", encoding="utf8", errors="ignore",
newline='')

#-- Préparation de l'objet d'ecriture au format CSV
objet_WriterOut = csv.writer(objet_fichier_csv_OUT, delimiter=';', quotechar='"',  quoting=csv.QUOTE_ALL, lineterminator='\n')

#-- Ecriture des éléments de la liste dans le fichier
objet_WriterOut.writerows(liste_lignes_metadonnee_technique_OUT)

#-- Fermeture du fichier
objet_fichier_csv_OUT.close()


#-------------------------------------------------------------------------------
# Traitement de création du fichier de métadonnées descriptives
#-------------------------------------------------------------------------------
#-- Ouverture du fichier CSV métadonnées descriptives en écriture
objet_fichier_csv_OUT = open(repertoire_fichier_metadonnee_OUT + '/' + nom_du_fichier_metadonnee_descriptive_OUT, "w", encoding="utf8", errors="ignore",
newline='')

#-- Préparation de l'objet d'ecriture au format CSV
objet_Writer_OUT = csv.writer(objet_fichier_csv_OUT, delimiter=';', quotechar='"',  quoting=csv.QUOTE_ALL, lineterminator='\n')

#-- Ecriture des éléments de la liste dans le fichier
objet_Writer_OUT.writerows(liste_lignes_metadonnee_descriptive_OUT)

#-- Fermeture du fichier
objet_fichier_csv_OUT.close()

#===============================================================================
```

```
################################################################################################
################################################################################################
#
# Exemple: Passage des lignes d'un fichier CSV dans une liste
#
# ==> Récupération des lignes du fichier de métadonnées techniques
#
################################################################################################
################################################################################################

#-- Chargement de la bibliotheque python pour la manipulation des fichiers CSV
import csv

#-- Initialisation des variables
liste_lignes_metadonnee_technique_IN = []


#-- Nom et Emplacement du fichier CSV de metadonnées techniques à importer
repertoire_fichier_metadonnee_IN = "C:/TD_DATALAKE/DATALAKE/2_CURATED_ZONE/METADONNEES"
nom_du_fichier_metadonnee_technique_IN = "metadonnee_technique.csv"


#-- Ouverture du fichier en lecture
objet_fichier_csv_IN = open(repertoire_fichier_metadonnee_IN + '/' + nom_du_fichier_metadonnee_technique_IN , "r", encoding="utf8", errors="ignore", newline='')

#-- Lecture du fichier CSV, segmentation des colonne, et stockage dans une liste
objet_Reader_IN = csv.reader(objet_fichier_csv_IN, delimiter=';', quotechar='"', quoting=csv.QUOTE_ALL, lineterminator='\n')

print(objet_Reader_IN)

#-------------------------------------------------------------------------------
#-- Test de visualisation du contenu de la liste de ligne à enregistrer dans un fichier
#-------------------------------------------------------------------------------
Sauter_une_ligne()
Afficher_une_ligne('=', 80)
for ligne_IN in objet_Reader_IN :
    print(ligne_IN)
    print(str(ligne_IN[1]))
    if str(ligne_IN[1]) == 'categorie_du_fichier_source':
        print('Le fichier à parser concerne le domaine : :', ligne_IN[2])
Afficher_une_ligne()

objet_fichier_csv_IN.close()

#================================================================================
```