PHASE 1

Lister le contenu du répertoire source « 0_SOURCE_WEB »

Copier les fichiers vers leurs répertoires respectifs en « LANDING ZONE »

Collecte/sélection des objets sources (fichiers HTML)

➔ Programme PYTHON à réaliser :

Collecter (Lister et copier) les objets (fichiers html) sans altération :

A partir de l'emplacement source :

C:\TD_DATALAKE\DATALAKE\0_SOURCE_WEB

Vers les emplacements cibles correspondant à leurs types **respectifs**

- Offre d'emplois Linkedin (INFO-EMP-LINKEDIN)
  C:\TD_DATALAKE\DATALAKE\1_LANDING_ZONE\LINKEDIN\EMP
- Information sur la société (INFO-SOC-GLASSDOOR)
  C:\TD_DATALAKE\DATALAKE\1_LANDING_ZONE\GLASSDOOR\SOC
- Avis des employées sur la société (AVIS-SOC-GLASSDOOR)
  C:\TD_DATALAKE\DATALAKE\1_LANDING_ZONE\GLASSDOOR\AVI

Ingestion des objets (fichiers HTML) en LANDING ZONE et création de métadonnées techniques (fichier CSV)

➔ Programme PYTHON à réaliser :

Récupération et stockage simultané des « Métadonnées Techniques » dans un fichier CSV selon le format et le modèle étudié en cours.

➔ **Important :**

Les objets sources ne doivent pas être modifiés (choisir une méthode de collecte non destructive)

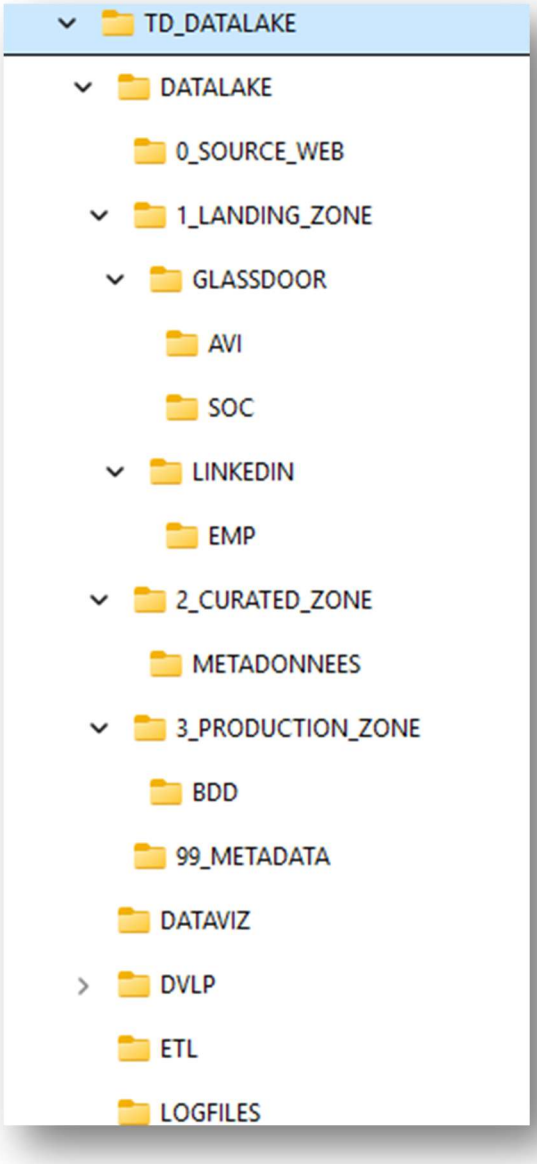
Les objets cibles devront être identiques aux objets sources (prévoir un contrôle)

Les "Métadonnées Techniques" pourront être enrichies (Exemples : voir CODE DUBLIN)

Vous réaliserez ces traitements en Python.

Vous pouvez vous appuyer si besoin sur le code python donné en exemple en « **ANNEXE 1 »** de ce document.

Structure du TD pour le stockage des objets en LANDING ZONE pour notre « Data Lake »



ANNEXE 1

```
# -*- coding: utf-8 -*-

#============================================================================================
#  Auteur: Eric KLOECKLE
#  Etablissement: Université Lumière Lyon 2 - Bron
#  Cursus: Master 2  BI&A : « Business Intelligence & Analytics »
#  Domaine: « Gestion de données massives »
#  Cours: Enseignement TD Datalake-House
#
#--------------------------------------------------------------------------------------------
# 01-PHASE-1_Recuperation_des_objets_HTML_source_vers_la_LANDINGZONE_avec_leurs_Metadonnes-Techniques_v0.01.py
#============================================================================================


##############################################################################
##############################################################################
#
# TRT01
#
#-----------------------------------------------------------------------------
#- Comment recuperer la date/time systeme
#
##############################################################################
##############################################################################
from datetime import datetime
def Get_datetime():
    Result = str(datetime.now().strftime('%Y-%m-%d %H:%M:%S'))
    return(Result)

print(Get_datetime())



##############################################################################
##############################################################################
#
# TRT02
#
#-----------------------------------------------------------------------------
#- Comment parcourir un dossier et stocker dans une liste, les noms de fichiers
#   filtrés selon des critères choisis
#
##############################################################################
##############################################################################

#-- Importation des bibliotheques necessaires
import os, fnmatch

#-- Initialisation des variables
liste_des_fichiers_html_tmp = []
liste_des_fichiers_html = []


#-- Utiliser dans le code comme sparateur d'arborescence des dossier soit "/" soit "\\"
#   mais jamais "\"
repertoire_des_fichiers_html_source = "C:/TD_DATALAKE/DATALAKE/0_SOURCE_WEB"


#-- Recupere dans une liste temporaire, les noms longs  des fichiers dans le path
liste_des_fichiers_html_tmp = os.listdir(repertoire_des_fichiers_html_source)

#-- Parametrage permettant de ne filtrer que les fichiers concernés parmis tous
#   les noms de fichiers de la liste
filtre_de_selection = "*INFO-EMP*.html"

#-- Parcourt tous les fichiers trouvés contenus dans la liste temporaire
#   et ajoute ceux correspondant au filtre dans la liste definitive
for nom_du_fichier_html_tmp in liste_des_fichiers_html_tmp :
    #-- On n'ajoute que les fichiers concernés
    if fnmatch.fnmatch(nom_du_fichier_html_tmp, filtre_de_selection)==True:
        liste_des_fichiers_html.append(nom_du_fichier_html_tmp)

#-- Affichage à l'écran du nom des fichiers fichiers contenus
#   dans la liste définitive
for nom_du_fichier in liste_des_fichiers_html : print(nom_du_fichier)



##############################################################################
##############################################################################
#
# TRT03
#
#-----------------------------------------------------------------------------
#-- Comment preparer les informations et les lignes à enregistrer dans votre
#   fichier de metadonnees techniques
#
##############################################################################
##############################################################################

#-- Importation des bibliotheques necessaires
import csv
```

```
#-- Verification visuelle que la liste des fichiers à recopier est correcte
for nom_du_fichier in liste_des_fichiers_html : print(nom_du_fichier)


#-- Initialisation des variables

liste_des_lignes_a_ecrire = []
#-- Creation de la 1ere ligne particulière du fichier (entete)
entete_fichier_csv = ["ID_OBJET","COLONNE","VALEUR"]
liste_des_lignes_a_ecrire.append(entete_fichier_csv)

print(liste_des_lignes_a_ecrire)

ID_Object = 0

#-- Exemple de boucle de traitment d'ecriture du fichier metadonnes techniques
for nom_du_fichier_html in liste_des_fichiers_html:
    #-- Repertoire source
    repertoire_des_fichiers_html_source = "C:/TD_DATALAKE/DATALAKE/0_SOURCE_WEB"

    #!!! Attention, dans cet exemple,  on ne traite que les données EMP  !!!
    #==> A adapter et compléter le code pour gérer les 2 autres types de données SOC, AVI
    #-- Repertoire cible
    repertoire_des_fichiers_html_cible = "C:/TD_DATALAKE/DATALAKE/1_LANDING_ZONE/LINKEDIN/EMP"

    chemin_du_fichier_html_source = repertoire_des_fichiers_html_source + "/" + nom_du_fichier_html
    chemin_du_fichier_html_cible = repertoire_des_fichiers_html_cible + "/" + nom_du_fichier_html

    #-- Creation d'une ligne pour la date d'ingestion
    liste_des_lignes_lues = [str(ID_Object), "date_ingestion", Get_datetime()]
    liste_des_lignes_a_ecrire.append(liste_des_lignes_lues)

    #-- Creation d'une ligne pour l'emplacement d'où l'on a récupéré le fichier
    liste_des_lignes_lues = [str(ID_Object), "path_name_file_source", chemin_du_fichier_html_source]
    liste_des_lignes_a_ecrire.append(liste_des_lignes_lues)

    #-- Creation d'une ligne pour l'emplacement où l'on a enregistré le fichier
    liste_des_lignes_lues = [str(ID_Object), "path_name_file_cible", chemin_du_fichier_html_cible]
    liste_des_lignes_a_ecrire.append(liste_des_lignes_lues)

    #-- Creation d'une ligne pour le type d'objet source
    liste_des_lignes_lues = [str(ID_Object), "type_objet_source", "INFO-EMP"]
    liste_des_lignes_a_ecrire.append(liste_des_lignes_lues)

    #-- Rajoutez d'autres métadonnées techniques si necessaire
    # ....
    # ....

    ID_Object = ID_Object + 1

#-- Verifiation visuelle contenue de la liste des metadonnées à eregistrer
for ligne_a_ecrire in liste_des_lignes_a_ecrire : print(ligne_a_ecrire, "\n")



################################################################################
################################################################################
#
# TRT04
#
#-------------------------------------------------------------------------------
#-- Ecriture directe de la liste le fichier CSV de metadonnees techniques
#    RQ: Ici la liste contiendra les lignes pour SOC, AVI et EMP qui seront
#         enregistrées à ce moment dans leur totalité
#
################################################################################
################################################################################

#-------------------------------------------------------------------------------
#-- Definir le nom et l'emplacement où sera stocké votre fichier metadonnes techniques
#-------------------------------------------------------------------------------
repertoire_du_fichier_metadonnee_technique = "C:/TD_DATALAKE/DATALAKE/2_CURATED_ZONE/METADONNEES"
nom_du_fichier_metadonnee_technique = "metadonnee_technique.csv"
chemin_du_fichier_metadonnee_technique = repertoire_du_fichier_metadonnee_technique + "/" + nom_du_fichier_metadonnee_technique

#-- Verification visuelle  u nom de fichier métadonnées techniques
print(chemin_du_fichier_metadonnee_technique)

#-- Affichage pour controle des ligne contenues dans la liste  enregistrer dans le fichier
for ligne_a_ecrire in liste_des_lignes_a_ecrire :  print(ligne_a_ecrire)

#-- Ouverture du fihier en append ("a" = ajout)
# objet_fichier_metadonnee_technique = open(myPathFileNameMetaDataOut, 'a', newline='', encoding="utf-8", errors="ignore")
objet_fichier_metadonnee_technique = open(chemin_du_fichier_metadonnee_technique, 'a', newline='')

#-- Ecriture en une seule commade de l'ensemble ds lignes contenues dans la liste que vous avez préparé
objet_WriterOut = csv.writer(objet_fichier_metadonnee_technique, delimiter=';', quotechar='"',  quoting=csv.QUOTE_ALL,
lineterminator='\n')

objet_WriterOut.writerows(liste_des_lignes_a_ecrire)

#-- Fermeture du fihier
objet_fichier_metadonnee_technique.close()
```

```
################################################################################
################################################################################
#
# TRT05
#
#-------------------------------------------------------------------------------
#-- Comment Copier TOUS les fichiers de la liste d'un repertoire dans un autre repertoire
#
################################################################################
################################################################################

#-- Importation des bibliotheques necessaires
import shutil

#-- Verification visuelle que la liste des fichiers à recopier est correcte
for nom_du_fichier in liste_des_fichiers_html :
    print(nom_du_fichier)

#-- Initialisation des variables
#-- Preciser le repertoire source
repertoire_des_fichiers_html_source = "C:/TD_DATALAKE/DATALAKE/0_SOURCE_WEB"

#-- Preciser le repertoire cible : (Exemple ici, pour recopier les fichiers EMP a partir de la liste correspondante)
repertoire_des_fichiers_html_cible = "C:/TD_DATALAKE/DATALAKE/1_LANDING_ZONE/LINKEDIN/EMP"

#-------------------------------------------------------------------------------
#-- !!! Ecrire ici l'entete dans le fichier de Metadonnes Techniques
#       ==> Ne le faire qu'une seule fois à la 1ere creation du fichier)
#-------------------------------------------------------------------------------

print("******** Debut de copie des fichiers ********")

#-- Boucle pour copier l'ensemble des fichiers contenus dans les listes des fichiers à recopier
#   ==> A compléter et adapter pour gérer pour les 3 listes SOC, AVI et EMP

for nom_du_fichier_html in liste_des_fichiers_html:
    #-- Preparation et affectation dans des variables
    #    des chemins complets des fchiers source et cible
    chemin_du_fichier_html_source = repertoire_des_fichiers_html_source + "/" + nom_du_fichier_html
    chemin_du_fichier_html_cible = repertoire_des_fichiers_html_cible + "/" + nom_du_fichier_html

    print("Copie du fichier : ", "\t", chemin_du_fichier_html_source, " -- vers -->", chemin_du_fichier_html_cible, "\n")
    #-- Lancement de la commande de copie du fichier
    shutil.copy(chemin_du_fichier_html_source, chemin_du_fichier_html_cible)

    #-----------------------------------------------------
    # Vous coderez ici une  partie enregistrement des METADONNEES TECHNIQUE :
    #
    #   - Recuperation de la date / Heure systeme
    #   - Preparation des lignes à enregistrer dans le fichier Metadonnees Techniques
    #   - Ouverture en append (ajout) du fichier et enregistrement des lignes formatees comme vu en cours
    #     et fourni dans vos ressources à dispositin sur le site u mooc
    #   - ...
    #   - fermeture du fichier Metadonnees Techniques
    #-----------------------------------------------------


    #-----------------------------------------------------

print("******** Fin de copie des fichiers ********\n")


################################################################################
################################################################################
#
#-- Exemple d'algorithme pour votre TD pour la phase d'ingestion
#   des données SOURCE  vers la LANDING ZONE + Metadonnees Technique
#
################################################################################
################################################################################

#- 1) Choix et Selection des objets source à ingérer dans votre DataLake
#
#- 2) Récupération (sans les altérer et à l'identique) des objets source vers la Landing Zone du Datalake
#
#- 3) Récupératon et stockage des métadonnées techniques obligatoire + celles que vous aurez ajouté au besoin
#       dans un fichier au format CSV  et de type Id/Key/Value.
#
#- 4) Preparer l'entete du fichier et l'écrire seulement une fois au début du fihier de métadonnées techniques
#       Exemple d'entete :  "ID_OBJET";"COLONNE";"VALEUR"
#
#- 5) Parcourir le dossier SOURCE et stocker respectivement dans 3 listes distinctes , les noms de fichiers
#       correspondant à chacun des 3 types de source d'information SOC, AVI et EMP.
#       (Voir le code python fourni dans ce document => TRT02)
#
#  6) Préparer la phase d'ingestion des objets et des données techniques
#
#    -  Preparer et realiser la copie des 3 type de fichiers sources dans leurs repertoires respectifs en utilisant
#         les listes précédement crées.
#         (Voir le code python fourni dans ce document => TRT05)
#
#    - Preparer les informations de metadonnées techniques et les lignes à enregistrer
#         (Voir le code python fourni dans ce document => TRT03)
#
#    - Enregistrer les informations de metadonnées techniques dans votre fichier
#         (Voir le code python fourni dans ce document => TRT04)
#
```